

Algoritmy přesného a přibližného vyhledávání.

Exact matching

forward matching

▷ naivní (brute force) algoritmus - $O(mn)$ time

▷ Roxy - Rabin - hledání pomocí hashovací funkce - $O(mn)$ time

- vypočítám hash vstupní (hledaného) - porovnám se rolling hash → jednoduše spočítám další element
- potom udeřím stejně se všemi substringy délky m
- můžu mít i false positives - musím ještě rekonstruovat

příklad: base = 5 mod = 10

$$p = aba \rightarrow 0 \cdot 5^2 + 1 \cdot 5^1 + 0 \cdot 5^0 = 5$$

další element spočítám jako $(prev - x \cdot 5^2) \cdot 5 + y \cdot 5^0$

▷ Morris - Pratt algorithm - $O(n)$ time, $O(m)$ space

$$\beta[i] = \beta[i-1] + 1$$

- se předem nachází symboly - v případě, že se nekročí, porovnám na hodnotu $\beta[i]$
- hodnota říká, jaký symbol má být po porovnání pod současným

▷ Knuth - Morris - Pratt algorithm

- vylepšení o efektivnější porovnávání

$$\beta''[i] = \text{KMP funkce}$$

$$\beta''[j] = j' \quad , \quad j'-1 \text{ je délka nejdelšího borderu } p[1 \dots j-1] \text{ kde se } p[j'] \neq p[j]$$

backward matching

▷ Boyer - Moore algorithm

$$x \quad \boxed{\quad a \quad u \quad \quad}$$

$$p \quad \boxed{\quad b \quad u \quad \quad}$$

$$\boxed{\quad c \quad u' \quad \quad}$$

→ good suffix shift


$$\boxed{\quad a \quad \text{not } a \quad \quad}$$

→ bad character shift

Boyer-Moore - Horspool


$O(nm)$

- BCS dle poslednich symbolu daného patternu



Boyer-Moore - Sunday

- next symbol in text



[Zhu - Takecka - používá dva symboly místo jednoho]




Approximate pattern Matching

- Edit distance - vzdálenost mezi dvěma řetězci
- o Hamming - pouze operace replace
- o Levenshtein (edit distance) - replace, delete, insert
 - dynamické programování

D	-	a	c	g	a	t
-	0	1	2	3	4	5
a	1	0	1	2	3	4
g	2	1	1	1	2	3
a	3	2	2	2	1	2
c	4	3	2	3	2	2
t	5	4	3	3	3	2

- o Weighted distance
- o Needleman - Wunsch algorithm - rozpoznávání řetězců v bioinformatice
 - ceny operací jsou různé hodnoty - různé váhové různé dráhy
 - + gap penalty - cena za mezeru (operace insert a delete)
 - cena se maximalizuje

- approximate string matching - hledám slova v textu se vzdáleností menší než k



- navíc operace transpose

[+bit parallelism]

i	1	2	3	4	5	6	7	8	9	10	11	12	13	14
p[i]	a	b	a	a	b	a	b	a	a	b	a	a	b	a
$\beta[i]$	0	0	1	1	2	3	2	3	4	5	6	4	5	6
$\beta'[i]$	0	1	1	2	2	3	4	3	4	5	6	7	5	6
$\beta''[i]$	0	1	0	2	1	0	4	0	2	1	0	7	1	0

- KMP - kuikeu se na peici $\beta'[i] = a \rightarrow$ tuleb $p[a] \neq p[i] \rightarrow \beta''[i] = a$
 \rightarrow tuleb $p[a] = p[i] \rightarrow \beta''[i] = \beta''[a]$

BMH:

p = abaabaa
6 5 4 3 2 1 0

c	BCH[c]
a	1
b	2
c	7

← minimum jē 1

a b c a b a a b a a a a a
 + " " " " "
 a b a a b a a
 a b a a b a a
 " " " " " " "
 ✓ a b a a b a a
 a b a a b a a
 " " " " " " "
 ✓ a b a a b a a