

Kontextové metody komprese dat

PPM - Prediction by partial matching

- tree for all found contexts
- each level for one context length

PPMA : escape symbol - pravděpodobnost $\frac{1}{1+n}$

PPMB : seeing twice is believing

PPMC : escape handled as others

PPM*

- dva různé kontexty, podle kterých se dá kódovat
- deterministický (vždy pokračují tím stejným symbolem)
 - hledám nejkratší kontext
- pokud není, považuje nedeterministický (jako u PPM)
- deterministický kontext může být neomezený (délka)

DCA

- řada slov, antidičionář
 - minimální řada slov
 - $x[1 \dots n-1]$ a $x[2 \dots n]$ nejsou řada slov
- komprese & dekomprese
 - output pouze to, co se měla jasně rozhodnout z AD
- konstrukce AD → strom → suffix linie do min. řady slov
- synchronizace ?

XXXX

- static
dynamic - 'jednočasové', bez synchronizácie, exceptions
almost universal - garin je povrch, ne všichni slova kódujeme
- 2 pass

ACB - Associate Codes of Burrows

- unbounded context and content
 - pairs inserted into dictionary & sorted right to left (by ~~the~~ context)
- output (d, l, a)
 - distance between best context and content
 - number of matched symbols
 - first unmatched in lookahead buffer

1	swiss m	context is swiss m
2	swi ss m	→ best match for it is between 2 & 3
3	s wiss m	(where would it appear sorted)
4	swi s s m	
5	swiss m	content is iss iss missing
6	sw iss m	→ best match is 4 symbols long at position 6

→ $(6-2, 4, i)$

clási varianta: - context matching at least k symbols

		b	tb
4	xx...x	0	zz...z 0...
5	xx...x	0	zz...z 1...
5	xx...x	1	

$(4, b, l)$ length $(tb-b)$
position mismatching bit

Symbol ranking - next symbol is often easy to guess (3 or 4 ~~guesses~~)

- context C of size n for symbol R → position of R in the list

